

uc3m

Universidad
Carlos III
de Madrid

Máster en Ingeniería Informática

Datos Masivos y Encadenados 2024-2025
Grupo 1

Práctica Obligatoria

“Parte 1: Integración de datos y funcional”

Luis Daniel Casais Mezquida – 100429021

Lucas Gallego Bravo – 100429005

Till Niklas Kobele – 100548395

Francisco Montañés de Lucas – 100406009

Diego Picazo García – 100549459

Equipo 3

Profesor

José Luis López Cuadrado

1. Resumen ejecutivo

Lo que se quiere conseguir a la hora de realizar este trabajo, es conseguir reunir en una única página web los lugares del planeta en los que se han conseguido certificar o validar avistamientos de ovnis. Mediante la utilización de una amplia gama de fuentes de datos heterogéneos pertenecientes a diferentes satélites y empresas se quiere lograr trazar en un mapa global en tres dimensiones dichos datos de tal forma que se pueda ver la ubicación del avistamiento y los datos relevantes a ese suceso.

Estas amplias fuentes de datos cuentan con datos en diferentes formatos, por lo que se cuenta con datos auditivos, imágenes, video y demás. Además, se quiere utilizar los datos pertenecientes a distintas compañías, tanto públicas como privadas con el fin de contrastar la información obtenida mediante diferentes fuentes sobre cada avistamiento.

Además, gracias al estado actual de la inteligencia artificial, se puede hacer uso de la misma con el fin de agilizar el trabajo, ya que por ejemplo, si se cuenta con audios muy largos se puede utilizar esta tecnología para que seleccione las secciones más interesantes de ese audio.

2. Arquitectura

La Figura 1 muestra el esquema general del sistema.

2.1. Extracción, procesamiento y almacenamiento de datos

Los datos serán extraídos a través de tres tipos de procesos distintos: *web scraping*, uso de APIs externas, y uso de fuentes de datos estáticos.

Web scraping

Los datos procedentes de páginas web serán extraídos mediante el uso de *web scraping*. Dado que éste es un proceso poco preciso, debido a la dificultad para obtener resultados acertados o válidos, los datos serán extraídos, filtrados, y agregados en un *data warehouse*, y serán procesados en el momento de la consulta. Este último procesamiento se realizará de esta manera debido al gran volumen de datos no estructurados que puede suponer el uso de este proceso de extracción.

La tarea de obtención de datos mediante *web scraping* será realizada periódicamente, y la frecuencia variará dependiendo de la necesidad, fuente y tipo de dato.




Fig. 1: Arquitectura general

APIs externas

Los datos procedentes de APIs externas usarán un *wrapper* por fuente, el cual será el encargado de extraer y transformar la información, homogeneizándola y poniéndola en un formato común.

Éstos *wrappers* formarán parte de una API cliente la cual será consumida por la aplicación. Las respuestas de éstas consultas también serán almacenadas en una caché, para así reducir el número de consultas a las APIs externas y reducir el tiempo de respuesta.

Datos estáticos

Los datos estáticos obtenidos de las fuentes de datos serán extraídos, transformados, y almacenados en una base de datos no relacional, para su posterior consulta. Los datos multimedia serán procesados mediante el uso de Inteligencia Artificial, específicamente redes de neuronas, para filtrar y categorizar datos relevantes.

2.2. Visualizado de la información

Para la visualización de la información, se creará una aplicación web. Ésta aplicación tendrá una arquitectura *backend for frontend*, la cual tiene dos componentes principales: un *frontend*, el cual será el encargado de la interfaz visual de la aplicación, y un servidor *backend*, el cual será el encargado de realizar las consultas a las diferentes fuentes de datos (el *data warehouse*, la API cliente, y la base de datos no relacional).

El *frontend* se comunicará con el *backend* usando tanto *manual triggering*, realizando las consultas a través de una petición explícita del usuario, como *long pooling*, lanzando consultas automáticas al *backend* en intervalos largos (de aprox. 40s). El formato de las comunicaciones será mediante peticiones de tipo REST.

3. Fuentes de datos

Podemos dividir las distintas fuentes de datos en tres tipos, dependiendo de qué proceso vamos a seguir para su extracción.

Web scraping

- MUFON (Mutual UFO Network) [1]: MUFON es una de las redes más grandes de investigación de OVNI, con una base de datos privada muy extensa con avistamientos por miembros de la asociación. Permite consultar los 20 reportes más recientes.
- NUFORC (National UFO Reporting Center) Dataset [2]: El National UFO Report-

ting Center es una página web recolectando y clasificando reportes de avistamientos de OVNI desde la década de 1950. Permite acceder a su base de datos mediante búsquedas en su web.

- UFO Stalker [3]: Recolecta reportes de avistamientos en su base de datos, que se puede ver en su web o mostrar en un mapa.
- SatNogs Data [4]: Aplicación web permitiendo un acceso a una base de datos unificada y colaborativa, con datos de localización y transmisiones de objetos espaciales artificiales (satélites y naves espaciales)
- SETI (Search for Extraterrestrial Intelligence) Data [5]: SETI almacena datos relacionados con la vida extraterrestre recogidos por satélites, permitiendo buscar y descargar estos datos de gran tamaño en su aplicación web.
- ESA Sky Data Hub [6]: Plataforma de datos espaciales que incluye imágenes del espacio profundo
- NASA Astronomy Picture of the Day (APOD) Random [7]: Acceso aleatorio a la colección de imágenes astronómicas diarias proporcionadas por la NASA.

Datos estáticos

- ESA NEO (Near Earth Object) Database [8]: Esta base de datos de la ESA se actualiza periódicamente para mostrar los NEO más recientes o más próximos en el tiempo. Los datos mostrados en la web pueden descargarse en varios formatos de archivo distintos.
- NASA NEOS (Near Earth Object Studies) Database [9]: Esta base de datos de la NASA se actualiza periódicamente para incluir NEOs o actualizar datos de los NEO registrados. Los datos se pueden filtrar de varias maneras en la web antes de poder descargarse en varios formatos de archivo distintos.
- NASA Fireballs Database [10]: Esta base de datos de la NASA se actualiza periódicamente para incluir bolas de fuego o bólidos detectados por sensores de la NASA. Los datos se pueden descargarse en varios formatos de archivo distintos.
- NASA Meteorite Database [11]: Esta base de datos de la NASA se actualiza muy poco, para incluir nuevos impactos de meteorito registrados. Los datos se pueden descargarse en varios formatos de archivo distintos.
- ESA (European Space Agency) Open Data [12]: La ESA proporciona acceso abierto a sets de datos que incluyen imágenes satelitales, mediciones climáticas, y muchos otros tipos de datos espaciales.

APIs externas

- SatNogs API [13]: API para extraer información de la base de datos unificada y colaborativa, con datos de localización y transmisiones de objetos espaciales artificiales (satélites y naves espaciales)
- SETI (Search for Extraterrestrial Intelligence) API [14]: SETI almacena datos relacionados con la vida extraterrestre recogidos por satélites, permitiendo buscar y descargar estos datos de gran tamaño mediante una API.
- NY2O API [15]: API de accesos limitados (1000 peticiones/h) sobre objetos espaciales para extraer su información TLE¹, o predecir su posición futura o localizaciones terrestres que sobrevolará.
- Google Maps API [16]: APIs de mapas de Google que te permite renderizar mapas interactivos con coordenadas geográficas.
- Google Maps Geocoding API [17]: API de Google Maps utilizada para convertir nombres de lugares en coordenadas geográficas.
- Mapbox APIs [18]: Proporciona mapas interactivos y herramientas de geolocalización personalizables, útiles para representar los datos.
- NASA Image and Video Library API [19]: Proporciona acceso a una vasta colección de imágenes, videos y audios relacionados con misiones espaciales de la NASA.
- NASA Astronomy Picture of the Day (APOD) API [20]: Acceso a la colección de imágenes astronómicas diarias proporcionadas por la NASA.
- Sentinel Hub API [21]: Acceso a la colección de imágenes satelitales terrestres de los satélites Sentinel de la ESA.
- NASA open-access APIs[22]: La NASA ofrece una variedad de APIs que cubren datos astronómicos, imágenes, videos y mucho más.

¹https://en.wikipedia.org/wiki/Two-line_element_set

Referencias

- [1] MUFON. «MUFON data.» (2004), dirección: https://mufoncms.com/last_20_public.html (visitado 20-10-2024).
- [2] NUFORC. «NUFORC data bank.» (2002), dirección: <https://nuforc.org/databank/> (visitado 20-10-2024).
- [3] ufostalker-data. «UFO Stalker database.» (2008), dirección: <https://ufostalker.com/ufo-sighting-list> (visitado 20-10-2024).
- [4] SatNOGS. «SatNOGS database.» (2016), dirección: <https://db.satnogs.org/> (visitado 20-10-2024).
- [5] B. SETI. «SETI data.» (2019), dirección: <http://seti.berkeley.edu/opendata/> (visitado 20-10-2024).
- [6] ESA. «ESA Sky Data Hub.» (2016), dirección: <https://sky.esa.int/esasky/> (visitado 20-10-2024).
- [7] NASA. «NASA Astronomic Picture Of the Day Random.» (1995), dirección: https://apod.nasa.gov/apod/random_apod.html (visitado 20-10-2024).
- [8] ESA. «ESA NEO Database.» (2016), dirección: <https://neo.ssa.esa.int/close-approaches> (visitado 11-11-2024).
- [9] NASA. «NASA CNEOS Database.» (2017), dirección: <https://cneos.jpl.nasa.gov/ca/> (visitado 11-11-2024).
- [10] NASA. «NASA Fireballs-Bolides Database.» (2017), dirección: <https://cneos.jpl.nasa.gov/fireballs/> (visitado 11-11-2024).
- [11] NASA. «NASA Meteorite Database.» (2015), dirección: https://data.nasa.gov/Space-Science/Meteorite-Landings/gh4g-9sfh/about_data (visitado 09-11-2024).
- [12] ESA. «ESA Open datasets.» (2017), dirección: <https://open.esa.int/> (visitado 20-10-2024).
- [13] SATNOGS. «SatNOGS API.» (2016), dirección: <https://db.satnogs.org/api/> (visitado 20-10-2024).
- [14] B. SETI. «SETI API.» (2019), dirección: <https://github.com/ggroode/bl-opendata> (visitado 08-11-2024).
- [15] NY2O. «NY2O API.» (2018), dirección: <https://www.n2yo.com/api/> (visitado 20-10-2024).
- [16] Google. «Google Maps APIs.» (2012), dirección: <https://developers.google.com/maps/apis-by-platform> (visitado 20-10-2024).
- [17] Google. «Google Maps Geocoding API.» (2020), dirección: <https://developers.google.com/maps/documentation/geocoding?hl=es-419> (visitado 11-11-2024).

- [18] Mapbox. «Mapbox API.» (2015), dirección: <https://docs.mapbox.com/api/overview/> (visitado 20-10-2024).
- [19] NASA. «NASA Image and Video Library API.» (2016), dirección: https://images.nasa.gov/docs/images.nasa.gov_api_docs.pdf (visitado 20-10-2024).
- [20] NASA. «NASA Astronomic Picture Of the Day API.» (2015), dirección: <https://github.com/nasa/apod-api> (visitado 20-10-2024).
- [21] NASA. «Sentinel Hub API.» (2015), dirección: <https://www.sentinel-hub.com/develop/api/> (visitado 20-10-2024).
- [22] NASA. «NASA Open APIs.» (2015), dirección: <https://api.nasa.gov/> (visitado 20-10-2024).